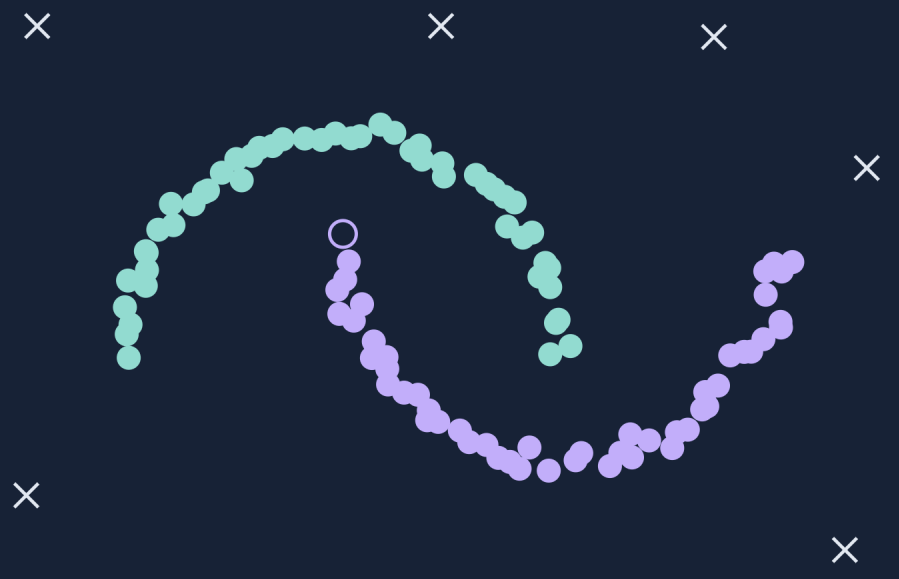
Hiyerarşik Kümeleme ve DBSCAN

Benzer verileri gruplamanın
iki farklı yolu



İlişkiler ve yoğunluk
Temsili hareket

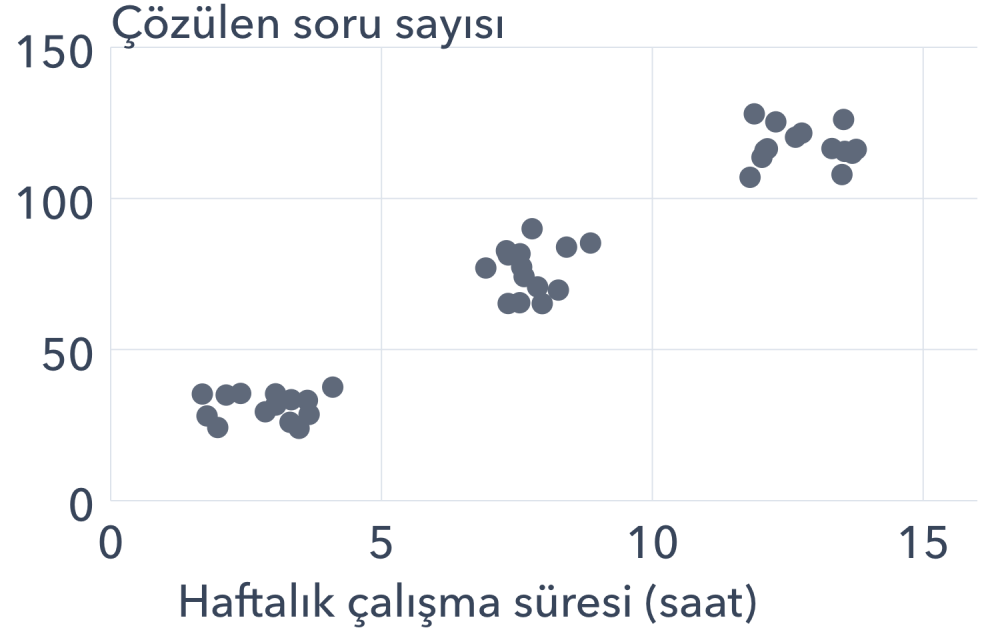
Kaynaklar [1] [5]

Konuşmacı penceresi · N

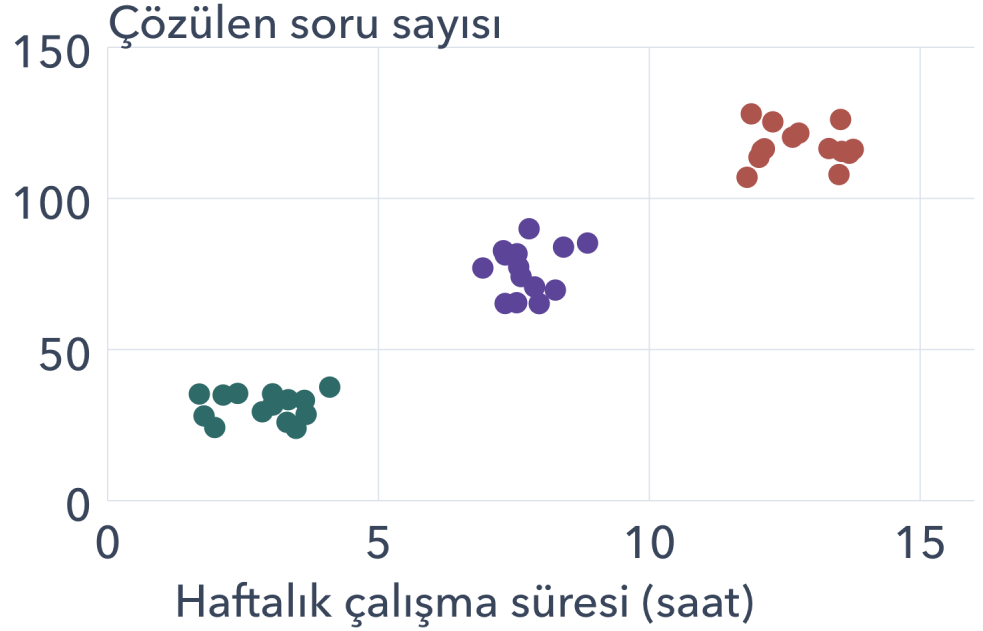
Etiketler verilmeden gruplar aranır

Benzer örnekler gruplanır. Grupların anlamını biz yorumlarız.

Başlangıç verisi



Örnek gruplama



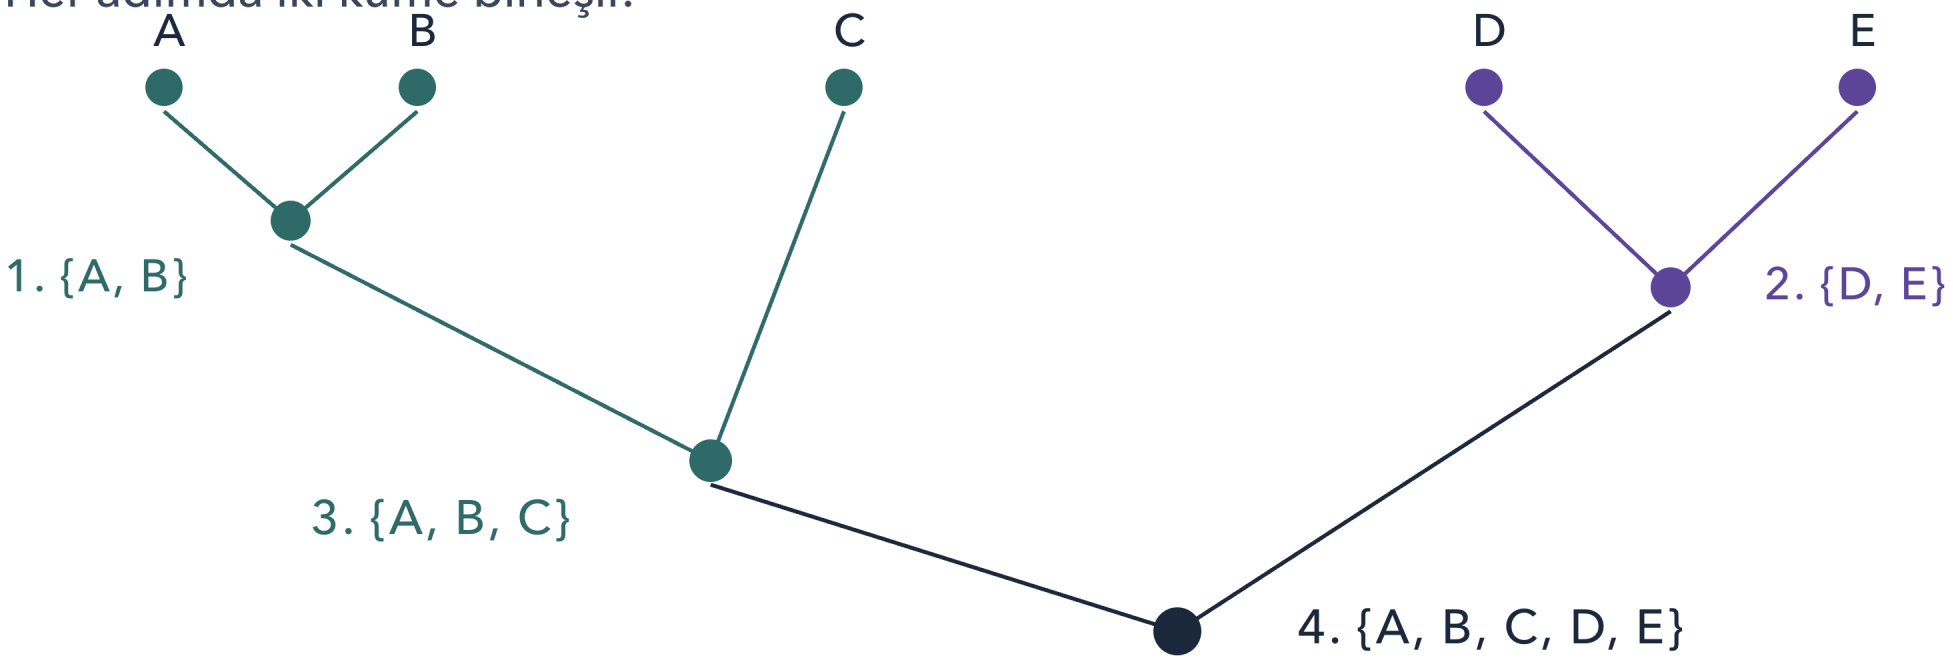
Temsili öğrenci verisi; renkler gruplama fikrini anlatır.

Kaynaklar [5]

Konuşmacı penceresi · N

Birleştirici ve bölücü yaklaşımlar

Birleştirici (Agglomerative): Her nokta ayrı başlar.
Her adımda iki küme birleşir.



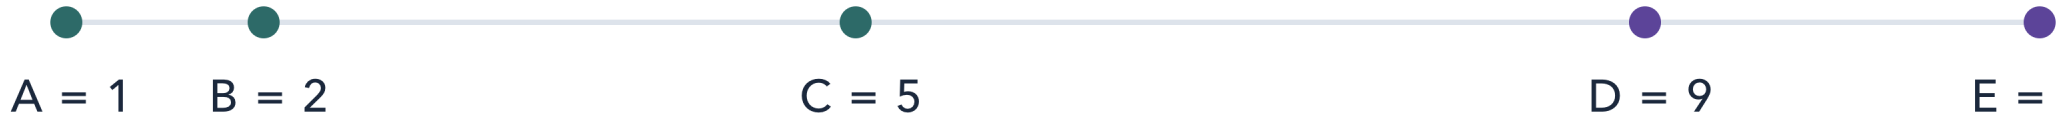
Bölücü (Divisive) Tüm noktalar birlikte başlar, aşamalı bölünür.

Kaynaklar [5] [6]

Konuşmacı penceresi · N

Single linkage ile dört birleşme

Tek boyutlu Öklid uzaklığı ve single linkage



ADIM	BİRLEŞEN KÜMELER	UZAKLIK
1	A ve B	1
2	D ve E	2
3	{A, B} ve C	3
4	{A, B, C} ve {D, E}	4

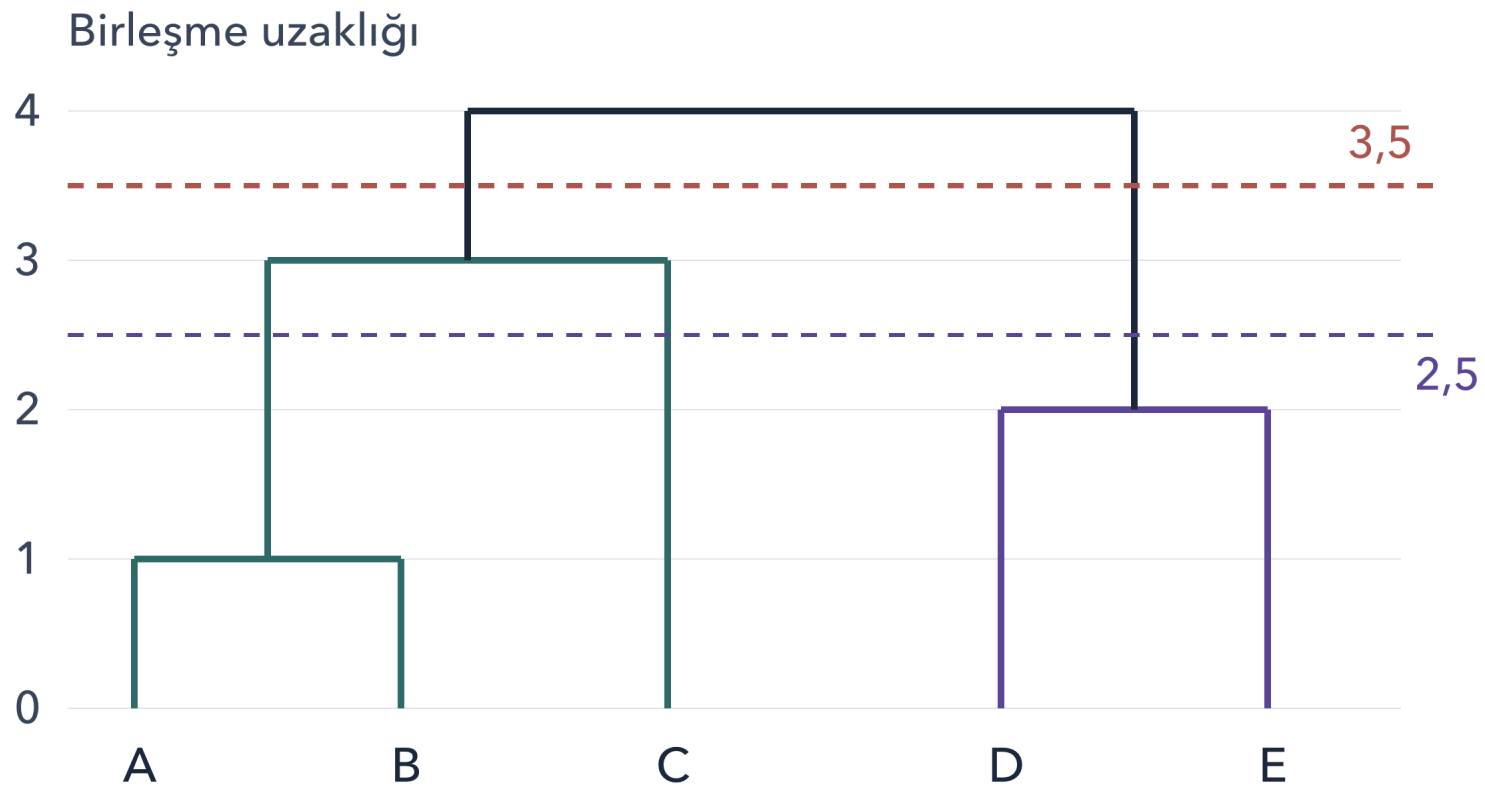
1, 2, 3, 4

Bu uzaklıklar dendrogramın birleşme yükseklikleridir.

Kaynaklar [3] [6]

Konuşmacı penceresi · N

Dendrogramda iki farklı kesim



2 küme

{A, B, C}

{D, E}

2,5 kesimi: 3 küme

{A, B}, {C}, {D, E}

Bu kez 3 küme oluşur.

Kaynaklar [3] [4]

Konuşmacı penceresi · N

Linkage, küme uzaklığını tanımlar

Küme 1 = {0, 2}

Küme 2 = {4, 8}



Çift uzaklıkları: |0−4|=4, |0−8|=8, |2−4|=2, |2−8|=6

Single	Complete	Average
2	8	5

Ward: Küme içi kareli sapmalar toplamındaki artışı en küçük tutar.
Öklid uzaklığı gerektirir.

Kaynaklar [3] [6]

Konuşmacı penceresi · N

Hiyerarşik yaklaşımın sınırları

Zincirleme etkisi	Single linkage, aradaki yakın noktalarla ayrı görünen grupları bağlayabilir.
Geri alınmayan birleşmeler	Klasik birleştirici süreçte erken birleşmeler sonradan düzeltilmez.
Hesaplama ve bellek	SciPy single, complete, average ve Ward için $O(n^2)$ zaman; linkage uygulamalarında $O(n^2)$ bellek.

Kaynaklar [3] [5] [6]

Konuşmacı penceresi · N

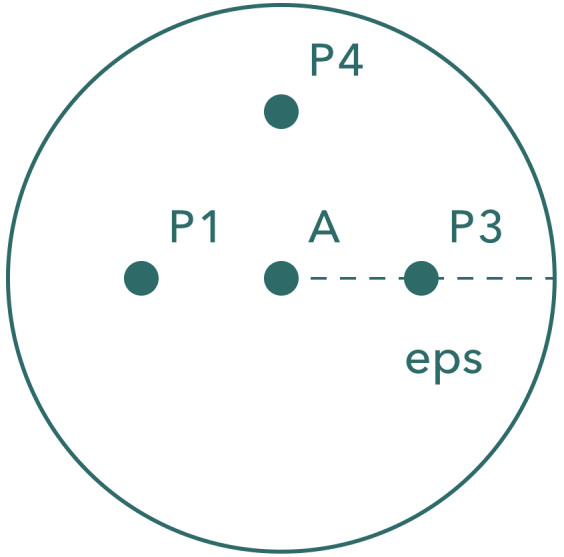
DBSCAN'de yoğunluk yereldir

eps

Yerel komşuluk uzaklığı eşiği

MinPts / min_samples

Çekirdek için gereken asgari sayı.
Noktanın kendisi de sayılır.



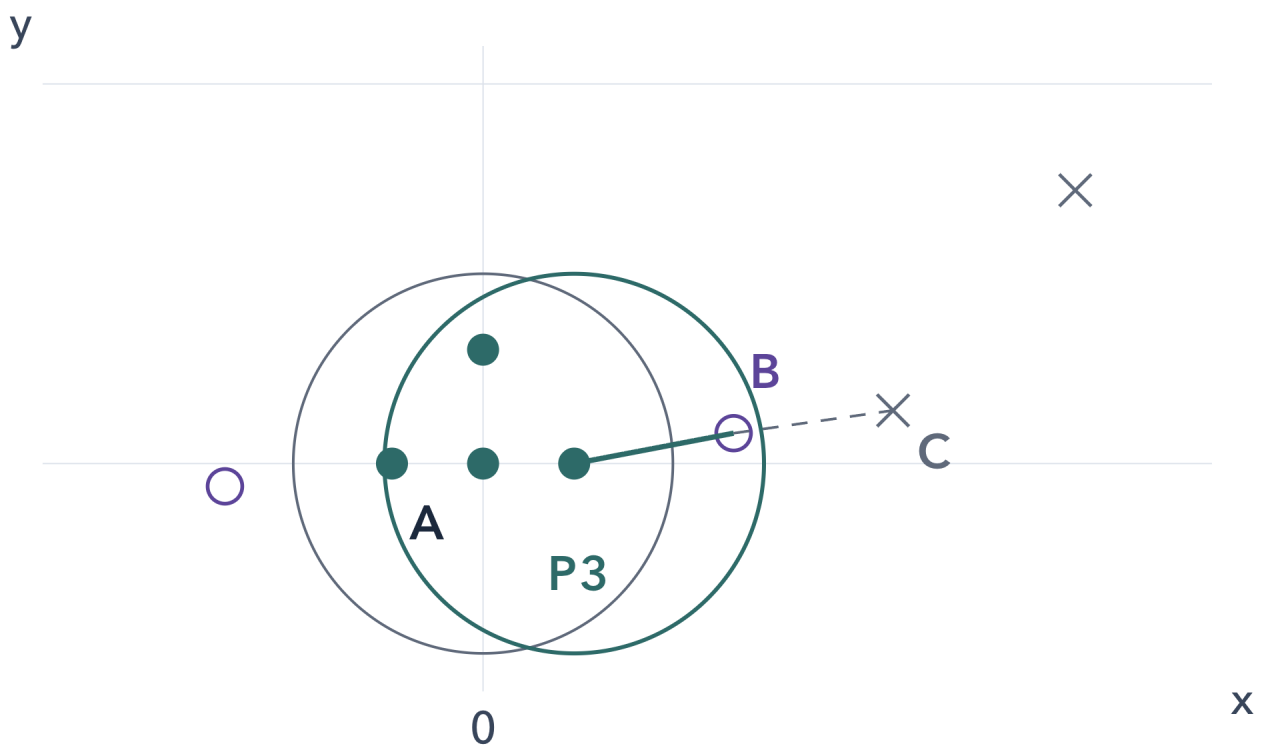
MinPts = 4

eps, bütün kümenin çapı değildir.

Kaynaklar [1] [7]

Konuşmacı penceresi · N

B’ye P3’ten ulaşılır; C dışarıda kalır



B sınırdır; C’ye doğru genişleme yapılamaz.

eps = 0,25 MinPts = 4

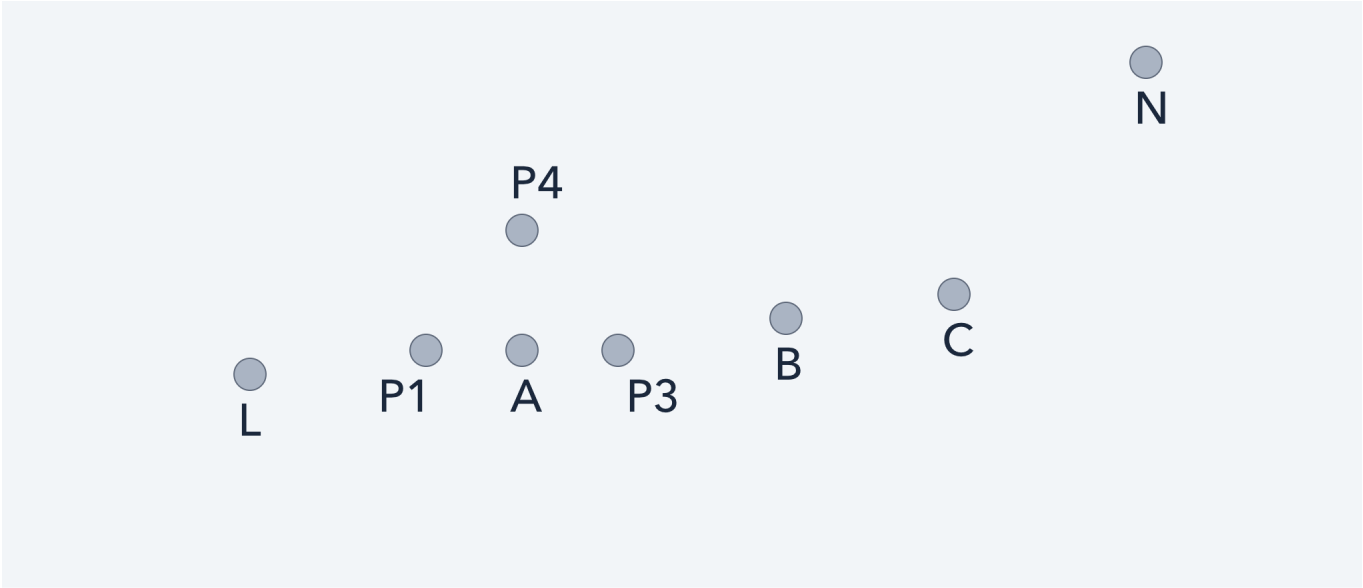
- **Çekirdek**
  P3’ün kendisi dahil 5 komşusu var.
- **Sınır**
  P3–B ≈ 0,214 ≤ eps
  B’de yalnız 3 komşu var.
- **Gürültü**
  B–C ≈ 0,212 olsa da P3–C ≈ 0,426 > eps.

Kaynaklar [1] [7]

Konuşmacı penceresi · N

Küme yalnız çekirdeklerden genişler

Aynı 8 nokta · eps = 0,25 · MinPts = 4 (kendisi dahil)



● Çekirdek ○ Sınır ✕ Gürültü ● İncelenmemiş ⬚ Sırada

İlk gürültü etiketi geçici olabilir; bir çekirdekten ulaşılırsa sınır olur.

ADIM 1 / 8

Henüz hiçbir nokta incelenmedi

Açık gri noktalar gürültü değildir. A ile başlayacağız; her komşulukta MinPts koşulunu kontrol edeceğiz.

Geri | Sonraki adım | Başa al

Adım 1 / 8

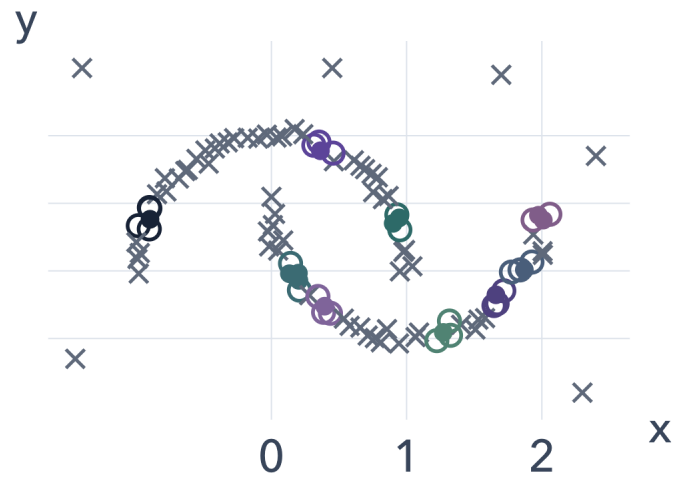
Kaynaklar [1] [2] [7]

Konuşmacı penceresi · N

Aynı veri, farklı eps değerleri

106 nokta, Öklid uzaklığı, MinPts = 4, ölçekleme yok.

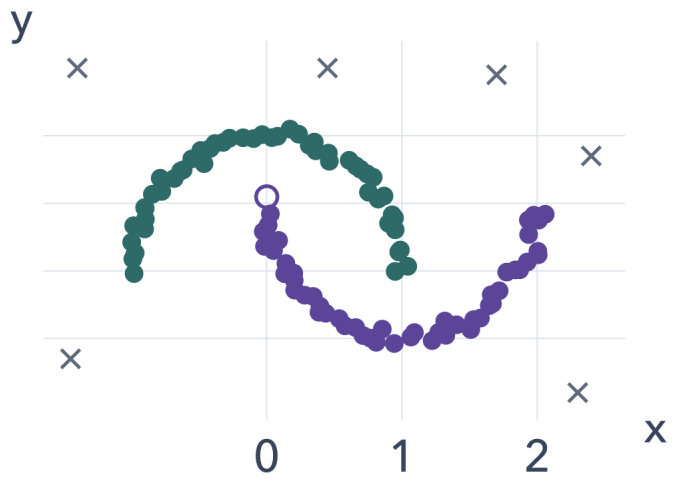
eps = 0,1



9 küme, 68 gürültü

Küçük eşik: parçalanma

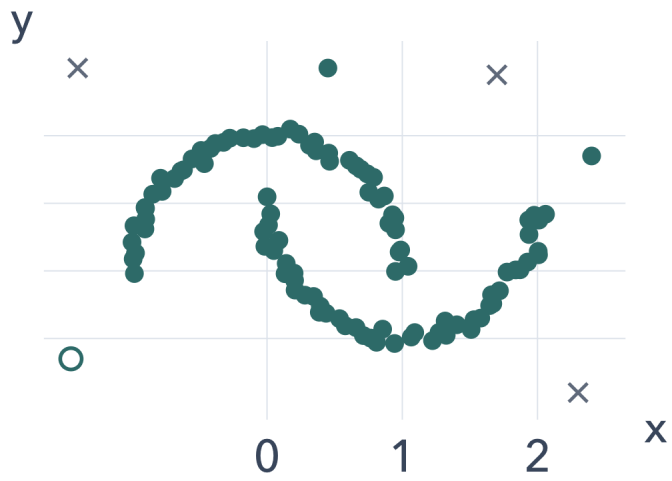
eps = 0,24



2 küme, 6 gürültü

0,24 bu örneğe özgüdür

eps = 0,8



1 küme, 3 gürültü

Büyük eşik: birleşme

Kaynaklar [2] [7]

Konuşmacı penceresi · N

Komşu uzaklıklarından eps adayına



1. Uzaklığı hesapla

Kendisi dışındaki 3. en yakın komşu.

2. Sırala

Uzaklıkları küçükten büyüğe yerleştir.

3. Adayları incele

Dirsek belirgin olmayabilir. Grafik garanti vermez.

Kaynaklar [1] [2] [7]

Konuşmacı penceresi · N

MinPts için bir başlangıç noktası

$$MinPts \approx 2d$$

d = özellik sayısı

$$d = 2$$

$$MinPts = 4$$

d+1 ve 2d gibi değerler başlangıç adaylarıdır.
Zorunlu kurallar değildir; veriyle değerlendirilir.

Kaynaklar [1] [2]

Konuşmacı penceresi · N

Ölçek, uzaklık hesabını değiştirir

Kayıt	Yaş	Yıllık gelir (TL)
A	20	30.000
B	21	70.000
C	50	32.000
D	51	72.000

	Ham uzaklık	StandardScaler sonrası
A–B	≈ 40.000	≈ 2,00
A–C	≈ 2.000	≈ 2,00

Sentetik örnek. Yaş: yıl, gelir: TL.

StandardScaler: z = (x − ortalama) / standart sapma

Dönüşüm probleme göre seçilir. Ölçekleme sonrası eps yeniden değerlendirilir.

Kaynaklar [8] [7]

Konuşmacı penceresi · N

Tek eps her yapıya uymaz

Farklı yoğunluklar	Tek eşik, seyrek grubu dışarıda bırakabilir veya ayrı grupları birleştirebilir.
Yüksek boyut	Uzaklık ve yoğunluk ayrımı zorlaşabilir.
Seçimlere duyarlılık	Özellikler, uzaklık ölçüsü, eps ve MinPts sonucu birlikte belirler.

HDBSCAN ve OPTICS farklı yoğunluklar için incelenebilir.
Yüksek boyut sorununu tamamen çözmezler.

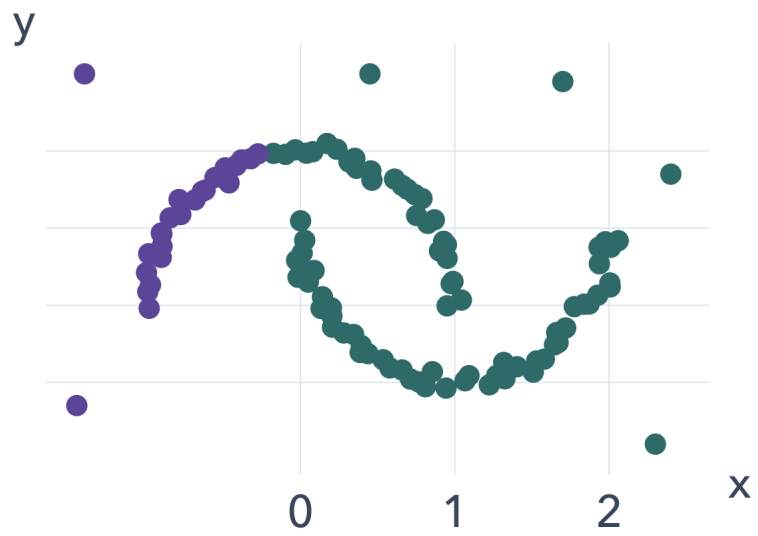
Kaynaklar [2] [5] [7] [9] [10]

Konuşmacı penceresi · N

Aynı veri, farklı sonuçlar

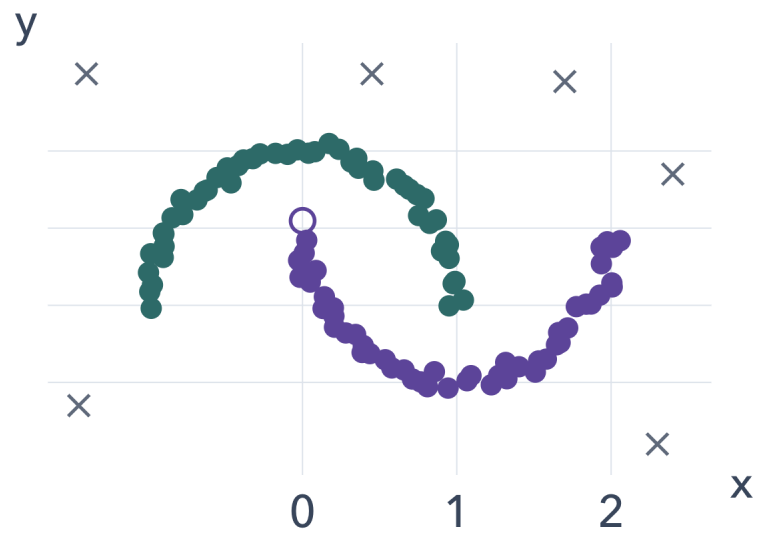
Ward sonucu, bütün hiyerarşik yöntemlere genellenmez.

Ward



Küme sayısı = 2, Öklid uzaklığı

DBSCAN



eps = 0,24, MinPts = 4, Öklid uzaklığı

Aynı 106 nokta, aynı eksenler ve ön işleme. Ölçekleme yok.

Kaynaklar [3] [6] [7]

Konuşmacı penceresi · N

İlişki ağacı ve yoğunluk bağlantısı

ÖZELLİK	HİYERARŞİK KÜMELEME	DBSCAN
Yaklaşım	Birleşme veya bölünme	Yoğunluk bağlantısı
Çıktı	Ağaç ve kesimdeki kümeler	Kümeler ve gürültü
Küme sayısı	Kesimle belirlenebilir	Doğrudan girilmez
Gürültü	Standart: gürültü etiketi yok	Özel gürültü etiketi var
Temel sınırlılıklar	Linkage, geri alınmayan birleşmeler ve maliyet	Tek yoğunluk eşiği ve yüksek boyut duyarlılığı

Kaynaklar [3] [5] [6] [7]

Konuşmacı penceresi · N

Kümeler, incelemeye yön verir

Belgeler	Benzer belgelerden konu grupları oluşturma
Müşteriler	Özelliklere göre segmentleri araştırma
Konum kayıtları	Yoğun bölgeleri bulma
Yoğunluk dışı kayıtlar	İncelemeye aday kayıtları ayırma

Gürültü etiketi tek başına hata, dolandırıcılık veya saldırı kanıtı değildir.

Kaynaklar [5] [7]

Konuşmacı penceresi · N

Seçim, aradığın çıktıya bağlı

Hiyerarşik kümeleme

Grup ilişkilerini
farklı seviyelerde incele.

DBSCAN

Yoğun bölgeleri ve
dışarıdaki noktaları ayır.

Anlamlı özellikler, uygun uzaklık ve değerlendirilmiş parametreler.

Kaynakça

Özgün makaleler

[1] Ester ve diğerleri, 1996

A Density-Based Algorithm for Discovering Clusters in Large Spatial Databases with Noise

KDD-96, 226–231 · Makaleyi aç

[2] Schubert ve diğerleri, 2017

DBSCAN Revisited, Revisited: Why and How You Should (Still) Use DBSCAN

ACM TODS 42(3), Article 19 · Makaleyi aç

Resmî belgeler

SciPy

[3] linkage [4] dendrogram

scikit-learn: kümeleme

[5] Rehber [6] Hiyerarşik [7] DBSCAN

Ölçekleme

[8] StandardScaler

Yoğunluk temelli alternatifler

[9] HDBSCAN [10] OPTICS

Konuşmacı penceresi · N